

ICC

Projet de fin de module

Machine Learning Monitoring



Contexte de l'application

Me: Mom can we get a

GAIA Leaderboard

Mom: No we have

GAIA Leaderboard

at home

at home:



Projet Micro IA 2026

Fichier Édition Affichage

GAIA Benchmark est un référentiel qui vise à évaluer les LLM de nouvelle génération.

Le but de ce projet sera de reproduire une telle application (vaguement, car vos grilles-pain de PC n'ont pas de GPU).



But de l'application

Considérons X librairies de Deep Learning, et X jeux de données partagés entre ces librairies.

- Comparer les performances de ces librairies sur ces datasets.
- Afficher en temps réel les états des processus de training de ces librairies.



Front

- CGU + Contacts
- Création de compte + Authentification/Déconnexion
- Affichage des performances



API

- Gère l'authentification et les tokens d'authentification
- Gère le training des modèles
- Gère la computation des résultats des modèles



Base de données

- Stocke les infos utilisateurs (Nom, Prénom, Droits, etc)
- Stocke les logs et les historiques de perfs
- Gère les données utilisées par le Backend



Stack technique :

- Frontend (choix ouvert)
- Message broker (Kafka)
- Backend REST (Python FastAPI)
- Programme de model training (Python)
- Librairies (PyTorch et Tensorflow Keras imposés, choix additionnels ouverts)
- Datasets de trainings (CIFAR 100 et Fashion MNIST, choix additionnels ouverts)
- Base de donnée relationnelle (choix ouvert)



Cahier des charges :

- Page d'accueil :
 - Formulaire de login
 - Bouton de création de compte qui renvoie vers un formulaire renseignant Nom et Prénom.
- Page principale :
 - Menu avec les graphes suivants :
 - Précision du modèle
 - Vitesse d'exécution
 - Utilisation du CPU par rapport à la machine hôte
 - Utilisation de la RAM par rapport à la machine hôte
 - **Contraintes :**
 - **Seul un user admin peut visualiser l'utilisation du CPU et de la RAM.**
 - **Les graphes doivent s'actualiser continuellement à des intervalles d'une durée maximale de 5 secondes.**
 - Contacts
 - CGU
 - Bouton de déconnexion



Contraintes techniques :

- Chaque brique applicative sera conteneurisée sous Docker.
- Le déploiement sera orchestré par Docker compose.
- Stockez vos datasets de training sur un volume que vous attacherez aux conteneurs qui doivent y avoir accès.
- Limitez les ressources de votre machine (CPU et mémoire) équitablement entre vos conteneurs de training, ou, si vous ne le faites pas, prenez explicitement en compte la disparité de ressources dans l'analyse des performances.
- Vos conteneurs de training ne communiquent pas directement avec d'autres services que le message broker.



Contraintes techniques :

- Il est impossible de passer une requête aux conteneurs de manière externe (cf `curl -X GET <ip-conteneur:port>/api/function`). Protégez les endpoints de vos API.



Tips :

- Pensez à sortir toute constante qui pourra créer de la configuration dans un fichier séparé.
- Choisissez judicieusement où stocker quelles informations.
- Ne développez que lorsque vous avez un schéma d'architecture clair et une vision d'ensemble de votre application.
- Git est votre meilleur ami ! Utilisez les branches et les PR à bon escient pour éviter de perdre du temps à vous échanger des fichiers.
- Faites vos tests sur un déploiement à blanc pour éviter que vos bases et votre cache web ne vous jouent des tours.



Rendu :

- Vous enverrez une archive contenant votre code source et votre schéma d'architecture avec un repo Git public dont chaque membre de votre groupe devra être collaborateur. Pas de gros push unique de code, les contributions de chaque élève peuvent entrer en compte dans la notation.
- Groupe de 3 max.
- Vous fournirez un jeu d'utilisateurs préexistants avec min 2 admins et 3 users dont les identifiants de connexion seront écrits dans le README.
- Une application maintenable mais partiellement fonctionnelle sera plus valorisée qu'une application non maintenable mais entièrement fonctionnelle.
- Votre projet doit se lancer uniquement avec la commande **docker-compose up -d --build**. Les rendus ne respectant pas cette condition ne seront pas évalués.
- **Retard = 0/20 !**
- **Utilisation de l'IA = 0/20 !**

Rendu : 31 Mars à 23h59

Lalanne Raphaël

